Previsão da Precipitação e Classificação do Risco Pluviométrico na Província de Maputo: SARIMAX, Random Forest e XGBoost

GAIO COTANE JOAO MAGAIA[1,*]

[1] *DARTA'ACOS, Consultoria e Estatística, Maputo, Moçambique*
[*] *Autor correspondente: cotanegayo@gmail.com; dea.dartacos@outlook.com*

Compiled 26 de outubro de 2026

Resumo. Previsões de curto prazo da precipitação são essenciais para o planeamento agrícola, a drenagem urbana e a preparação para emergências em Moçambique, onde a rede meteorológica é limitada. Este estudo comparou os modelos SARIMAX e Random Forest na previsão da precipitação do dia seguinte e na classificação do risco pluviométrico na Província de Maputo, com dados ERA5 de 1995 a 2024 (10.957 observações diárias). A metodologia incluiu análise exploratória, testes de Mann–Kendall, Dickey–Fuller e STL, e 21 preditores (calendário, defasagens, acumulados e médias móveis). O teste de Mann–Kendall indicou tendência decrescente fraca mas significativa na precipitação diária ($p = 0{,}0104$), sem tendências nos agregados anuais e sazonais. Os dados foram divididos cronologicamente, evitando o vazamento de informação. O SARIMAX(1,0,1) foi identificado por ACF/PACF; o Random Forest foi optimizado por validação cruzada temporal. Os resultados evidenciaram sazonalidade marcada, com 59,72% de dias sem chuva e máximo diário de 125,3 mm. O Random Forest optimizado superou o SARIMAX no teste (MAE 2,3569 mm, RMSE 5,6975 mm, $R^2 = 0{,}1567$), revelando relações não lineares. A precipitação do dia actual foi a variável mais importante, seguida da pressão média e da precipitação acumulada em sete dias. Na classificação do risco, o XGBoost obteve os melhores resultados (acurácia balanceada 0,3159, F1-score macro 0,3097), embora nenhum modelo identificasse os eventos de chuva extrema. Conclui-se que o Random Forest optimizado é o mais adequado para prever o volume diário de precipitação e o XGBoost para classificar o risco; ambos devem apoiar a decisão com observações locais e previsões oficiais, não como sistemas autónomos de alerta.

Palavras-chave: Precipitação; Random Forest; SARIMAX; XGBoost; Maputo.

Abstract. Short-term rainfall forecasts are essential for agricultural planning, urban drainage, and emergency preparedness in Mozambique, where the meteorological observation network is limited. This study compared SARIMAX and Random Forest models in forecasting next-day precipitation and classifying rainfall risk in Maputo Province, using ERA5 reanalysis data from 1995 to 2024 (10,957 daily observations). The methodology included exploratory analysis, Mann–Kendall, Dickey–Fuller and STL tests, and 21 predictors (calendar, lags, accumulations, and moving averages). The Mann–Kendall test indicated a weak but significant decreasing trend in daily precipitation ($p = 0.0104$), with no significant trends in annual and seasonal aggregates. Data were split chronologically to prevent information leakage. SARIMAX(1,0,1) was identified through ACF/PACF; Random Forest was optimized by temporal cross-validation. Results showed marked seasonality, with 59.72% of rain-free days and a daily maximum of 125.3 mm. The optimized Random Forest outperformed SARIMAX on the test set (MAE 2.3569 mm, RMSE 5.6975 mm, $R^2 = 0.1567$), revealing nonlinear relationships. Same-day precipitation was the most important variable, followed by mean pressure and seven-day accumulated precipitation. For risk classification, XGBoost achieved the best results (balanced accuracy 0.3159, macro F1-score 0.3097), although no model identified extreme rainfall events. The optimized Random Forest is the most suitable for forecasting daily precipitation volume and XGBoost for risk classification; both should support decision-making with local observations and official forecasts, rather than act as standalone alert systems.

Keywords: Rainfall; Random Forest; SARIMAX; XGBoost; Maputo.

1. INTRODUCTION

A. Contextualização do estudo

A chuva aplica influência directa sobre a agricultura, a drenagem urbana, os transportes, as obras e outras actividades económicas na Província de Maputo. A sua distribuição alternada, marcada pela alternância entre uma época chuvosa e uma época seca, pode dificultar o planeamento quando as decisões dependem da ocorrência ou da intensidade da chuva no dia seguinte. Esta situação torna a previsão de curto prazo relevante para apoiar a preparação de actividades e a redução de riscos associados a episódios de precipitação intensa.

O uso de dados meteorológicos observados é importante para representar as condições locais. Contudo, a disponibilidade e a continuidade das séries diárias de estações de superfície podem ser limitadas. Moçambique ainda enfrenta desafios relacionados com a cobertura, manutenção e disponibilidade da rede de observação meteorológica [1]. Neste contexto, os dados ERA5 constituem uma alternativa útil, pois fornecem séries temporais contínuas de variáveis meteorológicas e são produzidos através da combinação de observações com um sistema de reanálise numérica [2].

Apesar dessa vantagem, o ERA5 não corresponde a uma medição directa realizada num ponto específico. Por isso, os seus valores de precipitação podem não representar completamente a variabilidade local, sobretudo durante eventos convectivos

intensos. A utilização do ERA5 neste estudo deve, assim, ser entendida como uma abordagem de modelação para a área representada pelos dados, e não como substituição definitiva das observações pluviométricas locais. Sempre que possível, os resultados devem ser comparados com dados do INAM ou de estações próximas, como Maputo/Mavalane, e com produtos complementares de precipitação, como o CHIRPS [3].

Do ponto de vista da tomada de decisão, a previsão do volume de precipitação e a classificação do risco respondem a necessidades distintas. A primeira indica a quantidade provável de chuva, enquanto a segunda transforma essa estimativa em categorias com interpretação mais simples para utilizadores não especializados. Neste estudo, foram adoptadas cinco categorias: sem chuva, chuva fraca, chuva moderada, chuva forte e chuva extrema. Estes limites foram utilizados como uma classificação operacional para a análise e não devem ser interpretados como um sistema oficial de alerta meteorológico.

Embora SARIMAX e Random Forest sejam utilizados em estudos de previsão meteorológica, o seu desempenho pode variar conforme a região, a escala temporal, as variáveis disponíveis e a distribuição da precipitação. Assim, permanece relevante avaliar qual dos modelos oferece maior utilidade para prever a precipitação do dia seguinte na área estudada, bem como verificar quais variáveis contribuem mais para essa previsão. Este estudo compara os dois modelos com base em dados ERA5 de 1995 a 2024, avaliando simultaneamente a previsão do volume de precipitação, a classificação do risco pluviométrico com 24 horas de antecedência e a importância das variáveis meteorológicas.

B. Problema de pesquisa

Moçambique está vulnerável a cheias, ciclones e secas devido à sua localização costeira e às principais bacias hidrográficas. No sul, as bacias do Limpopo, Incomáti, Umbelúzi e Maputo aumentam a exposição a inundações [4]. A Província de Maputo também enfrenta riscos associados à precipitação intensa e à sua localização costeira [5].

A precipitação afecta a agricultura, a drenagem urbana, os transportes e a gestão de emergências. No período de 1995–2014, Moçambique registou uma precipitação média anual de 909,13 mm, com variações entre regiões [6].

A previsão diária continua difícil, pois a chuva varia no espaço e no tempo, e os eventos intensos podem ser localizados e de curta duração. A limitação da rede de observação meteorológica também dificulta a obtenção de séries locais contínuas [1].

Neste contexto, o ERA5 fornece séries contínuas de precipitação e de outras variáveis meteorológicas. Contudo, por ser uma reanálise, não representa directamente uma estação específica e pode diferir das observações locais, sobretudo em eventos intensos [2].

O SARIMAX permite modelar a dependência temporal e incorporar variáveis exógenas, enquanto o Random Forest capta relações não lineares. Assim, esta pesquisa compara o desempenho dos dois modelos na previsão da precipitação do dia seguinte, com 24 horas de antecedência, na área representada pelos dados da Província de Maputo. Avalia também a classificação do risco pluviométrico e identifica as variáveis mais relevantes, utilizando dados ERA5 de 1995 a 2024.

C. Justificativa

A sua variabilidade e a ocorrência de eventos intensos dificultam o planeamento com antecedência, tornando relevante a previsão da chuva do dia seguinte para apoiar decisões operacionais.

A disponibilidade limitada de séries meteorológicas locais contínuas reforça a utilidade dos dados ERA5, que permitem analisar um período extenso e incorporar diferentes variáveis meteorológicas. Contudo, por se tratar de dados de reanálise, é necessário avaliar o desempenho dos modelos na área de estudo e reconhecer as limitações da sua representação local [1, 2].

A comparação entre SARIMAX e Random Forest justifica-se pelas diferenças entre os dois métodos. O SARIMAX representa a dependência temporal da precipitação, enquanto o Random Forest permite modelar relações não lineares entre as variáveis e as suas defasagens. A avaliação conjunta da previsão do volume, da classificação do risco pluviométrico e da importância das variáveis permite verificar qual abordagem oferece maior utilidade para o apoio à tomada de decisão.

Assim, a pesquisa é justifica-se por produzir evidências específicas para a área representada pelos dados da Província de Maputo, utilizando o período de 1995 a 2024. Os resultados poderão apoiar análises meteorológicas e decisões de curto prazo, sem substituir as previsões oficiais nem os sistemas de alerta das entidades competentes.

C.1. Objectivo geral

Analisar o desempenho dos modelos SARIMAX e Random Forest na previsão da precipitação do dia seguinte e identificar as variáveis que mais contribuem para essa previsão na Província de Maputo, utilizando dados ERA5 do período de 1995 a 2024.

C.2. Objectivos específicos

1. Comparar o desempenho dos modelos SARIMAX e Random Forest na previsão da precipitação do dia seguinte;
2. Avaliar a capacidade dos modelos na classificação do risco pluviométrico com 24 horas de antecedência;
3. Identificar as variáveis meteorológicas mais relevantes para a previsão da precipitação.

2. REVISÃO DA LITERATURA

A. Precipitação e variabilidade meteorológica em regiões tropicais

A precipitação em Moçambique apresenta forte sazonalidade, mas o início e o fim da época chuvosa variam entre os anos, devido à influência de padrões atmosféricos e da temperatura da superfície do mar [7]. A circulação do Canal de Moçambique também influencia o transporte de humidade e a precipitação no sudeste africano [8]. Fenómenos como ENSO, IOD e IOPD podem contribuir para a previsibilidade sazonal, mas os seus efeitos variam conforme a região e o horizonte temporal [9]. Por isso, não devem ser transferidos automaticamente para a previsão diária em Maputo.

B. Dados ERA5 e limitações da precipitação de reanálise

O ERA5 combina observações meteorológicas, modelos numéricos e assimilação de dados, fornecendo séries contínuas de variáveis atmosféricas desde 1940 [**?**]. Contudo, não corresponde directamente às medições de um pluviômetro. A precipitação é estimada numa grelha espacial e pode diferir das observações locais, sobretudo nos trópicos e durante eventos convectivos intensos. Estudos identificam dificuldades na representação dos máximos diários e do momento da chuva [10, 11]. Assim, o ERA5 deve ser tratado como fonte de informação meteorológica, e não como verdade observacional absoluta.

C. Previsão de precipitação com modelos estatísticos

Os modelos ARIMA e SARIMA representam dependências temporais através de componentes autorregressivas, médias móveis, diferenciação e sazonalidade. O SARIMAX acrescenta variáveis exógenas, permitindo relacionar a precipitação com outros elementos meteorológicos. Estes modelos podem ser úteis em previsões de curto prazo, mas o desempenho depende do local, do horizonte e da métrica utilizada [12].

Aplicações do SARIMAX indicam utilidade na previsão de séries sazonais [13]. Porém, a precipitação diária apresenta muitos zeros, assimetria e eventos extremos, o que pode limitar os modelos lineares. Alguns estudos recorrem, por isso, a modelos híbridos que combinam métodos estatísticos e aprendizagem automática [14].

D. Aprendizagem automática na previsão meteorológica

Os métodos de aprendizagem automática representam relações não lineares e interacções entre variáveis meteorológicas. O Random Forest combina várias árvores de decisão e pode ser utilizado em regressão e classificação [15]. Contudo, a literatura não demonstra superioridade universal deste modelo. Estudos sobre chuva tropical identificam dificuldades na previsão de eventos raros e na representação da precipitação intensa [16]. Outros trabalhos mostram que o desempenho depende da região, da escala temporal e das variáveis utilizadas [17]. A importância das variáveis deve, portanto, ser interpretada como contribuição preditiva, não como causalidade.

E. Comparação entre SARIMAX e Random Forest

O SARIMAX enfatiza a dependência temporal e o efeito das variáveis exógenas, enquanto o Random Forest procura relações não lineares e interacções entre preditores. Estudos comparativos apresentam resultados diferentes conforme o problema analisado: em alguns casos, os modelos estatísticos superam o Random Forest; noutros, ocorre o contrário [18, 19]. Estes resultados não permitem definir antecipadamente o melhor modelo para Maputo, pois utilizam dados, períodos, alvos e métricas diferentes.

F. Classificação do risco pluviométrico

A previsão contínua em milímetros pode ser convertida em categorias para facilitar a interpretação. Porém, os limites dependem da climatologia, da duração do acumulado e da finalidade da análise. Uma categoria de chuva forte não equivale automaticamente a risco de inundação, que também depende da exposição, da vulnerabilidade e das condições locais.

Em séries com eventos raros, a acurácia pode favorecer as classes mais frequentes. Por isso, devem ser consideradas métricas como precisão, *recall*, F1-score, *balanced accuracy*, Brier score e calibração [20]. A escolha dos limiares deve ser definida antes da avaliação final, considerando a frequência dos eventos e os custos de falsos alarmes e falhas [21].

3. METODOLOGIA

A. Dados e área de estudo

Foram utilizados dados de reanálise ERA5 para a área representada pelas coordenadas de Maputo, aproximadamente 25,97°S e 32,59°E. O período analisado compreendeu 1 de Janeiro de 1995 a 30 de Dezembro de 2024. O ERA5 fornece estimativas meteorológicas contínuas obtidas através da combinação de observações e modelação numérica [**?**].

A base inicial continha 10.958 observações diárias e 17 colunas. Após a remoção do registo de 31 de Dezembro de 1994, que estava fora do período definido, permaneceram 10.957 observações. Foram seleccionadas cinco variáveis: temperatura média (°C), precipitação total (mm), humidade relativa média (%), pressão média (hPa) e velocidade máxima do vento (km/h). A precipitação total foi definida como variável-alvo.

B. API e processamento dos dados

A extracção dos dados foi realizada através de uma *Application Programming Interface* (API), que permite o acesso automatizado a dados de uma aplicação ou serviço. A preparação inicial foi realizada em Python, incluindo a conversão das datas, a verificação de registos duplicados, a identificação de valores em falta e a selecção das variáveis.

Não foram encontrados registos duplicados, valores ausentes ou falhas no intervalo temporal após a remoção do primeiro registo. Os valores de precipitação iguais a zero foram mantidos, por representarem dias sem ocorrência de chuva e constituírem observações válidas.

C. Análise de tendência

C.1. Teste de Mann–Kendall

O teste de Mann–Kendall foi utilizado para verificar a existência de uma tendência monotónica na série de precipitação. A hipótese nula (H_0) assume a inexistência de tendência, enquanto a hipótese alternativa (H_1) indica tendência crescente ou decrescente. A estatística do teste é dada por:

$$S = \sum_{i=1}^{n-1} \sum_{j=i+1}^{n} \operatorname{sgn}(x_j - x_i),$$

em que x_i e x_j são observações da série. O teste é não paramétrico e não exige que os dados apresentem distribuição normal [22, 23].

C.2. Declive de Sen

O declive de Sen foi utilizado para estimar a magnitude da tendência. Para cada par de observações, calcula-se:

$$Q_{ij} = \frac{x_j - x_i}{j - i}, \qquad i < j.$$

O declive final corresponde à mediana dos valores Q_{ij} e representa a variação da precipitação por unidade de tempo [24].

D. Decomposição STL

A série mensal acumulada foi decomposta pelo método STL (*Seasonal-Trend decomposition using Loess*). A decomposição separa a série observada em tendência, sazonalidade e resíduo:

$$Y_t = T_t + S_t + R_t,$$

em que Y_t representa a série observada, T_t a tendência, S_t a componente sazonal e R_t o resíduo. O procedimento permitiu observar a estrutura sazonal e a evolução temporal da precipitação [25].

E. Estacionariedade e autocorrelação

E.1. Teste de Dickey–Fuller aumentado

A estacionariedade da série diária de precipitação foi avaliada através do teste de Dickey–Fuller aumentado (ADF). A estatística obtida foi $-10{,}35139$, com $p = 2{,}53126 \times 10^{-18}$. Como o

valor de p foi inferior a 0,05, rejeitou-se a hipótese nula de existência de uma raiz unitária. A série foi, portanto, considerada estacionária e adoptou-se $d = 0$ no modelo SARIMAX [26].

E.2. ACF e PACF

As funções de autocorrelação (ACF) e autocorrelação parcial (PACF) foram analisadas para identificar a dependência temporal da precipitação e apoiar a definição preliminar das ordens do modelo. Em ambas, observou-se um valor elevado no primeiro desfasamento, enquanto os desfasamentos seguintes apresentaram valores próximos de zero. Com base neste comportamento, foram consideradas ordens autorregressivas e de média móvel baixas, posteriormente comparadas através dos critérios AIC, BIC e do teste de Ljung–Box.

F. Engenharia de variáveis

A variável-alvo foi definida como a precipitação do dia seguinte ($t + 1$). Foram utilizados exclusivamente dados disponíveis até ao dia t, evitando informação posterior ao momento da previsão.

Foram construídos 21 preditores, incluindo o mês, um indicador da época chuvosa, a precipitação do dia actual, as defasagens de 1, 3 e 7 dias, os acumulados de precipitação de 3, 7 e 30 dias, os valores actuais de temperatura, humidade, pressão e vento, bem como as médias móveis de 3 e 7 dias dessas variáveis.

Após a aplicação da janela de 30 dias, necessária para calcular os acumulados e as médias móveis, permaneceram 10.927 registos completos para a modelação.

G. Material

Os dados utilizados neste estudo foram obtidos através da Application Programming Interface (API) do ERA5, produto de reanálise climática global desenvolvido pelo Centro Europeu de Previsões Meteorológicas a Médio Prazo (ECMWF). O ERA5 fornece estimativas horárias de um grande número de variáveis atmosféricas, terrestres e oceânicas, cobrindo a Terra numa grelha de 31 km de resolução espacial, com dados disponíveis desde 1940 até ao presente [**?**]

Para o presente estudo, foram extraídas séries temporais diárias para a localização geográfica de Maputo (latitude: 25.97°S, longitude: 32.59°E), O período analisado foi de 1 de Janeiro de 1995 a 30 de Dezembro de 2024, totalizando 10.957 observações diárias após a remoção do registo de 31 de Dezembro de 1994. automaticamente pela API do ERA5 como ponto de referência inicial, foi removida na fase de pré-processamento dos dados, garantindo a integridade do período de análise.

As variáveis meteorológicas extraídas foram as seguintes: pressão atmosférica máxima, mínima e média (hPa), temperatura do ar máxima, mínima e média (°C), precipitação total diária (mm), precipitação sob forma de chuva (mm), humidade relativa máxima, mínima e média (%), velocidade máxima do vento (km/h), velocidade máxima de rajada (km/h) e direcção dominante do vento (°), totalizando 14 variáveis meteorológicas e 3.652 observações diárias [**?**].

Tabela 1. Variáveis meteorológicas extraídas do ERA5

Variável	Descrição	Unidade
Pressão Máx/Mín/Méd	Pressão atmosférica	hPa
Temp. Máx/Mín/Méd	Temperatura do ar	°C
Precipitação Total	Precipitação diária	mm
Chuva	Precipitação líquida	mm
Humidade Máx/Mín/Méd	Humidade relativa	%
Vel. Vento Máx	Velocidade do vento	km/h
Rajada Máx	Rajada máxima	km/h
Direcção Vento	Direcção dominante	°

H. Ferramentas

O processamento e análise dos dados foram realizados com recurso a dois ambientes computacionais complementares. A extracção e o pré-processamento dos dados ERA5 foram efectuados em linguagem Python, através da plataforma Google Colaboratory (Colab), utilizando as bibliotecas *openmeteo-requests* para acesso à API, *pandas* para manipulação dos dados e *openpyxl* para exportação em formato Excel.

A análise estatística e a modelagem preditiva foram realizadas no ambiente RStudio, utilizando a linguagem R, reconhecida pela sua robustez no tratamento de séries temporais e na implementação de modelos estatísticos e de Machine Learning. Os pacotes utilizados incluem, entre outros, *forecast* para modelagem de séries temporais, *Kendall* para detecção de tendências, *randomForest* para modelagem preditiva e *ggplot2* para visualização gráfica dos resultados.

I. Estacionariedade e autocorrelação

I.1. Teste de Dickey–Fuller aumentado

A estacionariedade da série diária de precipitação foi avaliada através do teste de Dickey–Fuller aumentado (ADF). A estatística obtida foi $-10{,}35139$, com $p = 2{,}53126 \times 10^{-18}$. Como o valor de p foi inferior a 0,05, rejeitou-se a hipótese nula de existência de uma raiz unitária. A série foi, portanto, considerada estacionária e adoptou-se $d = 0$ no modelo SARIMAX [26].

I.2. ACF e PACF

As funções de autocorrelação (ACF) e autocorrelação parcial (PACF) foram analisadas para identificar a dependência temporal da precipitação e apoiar a definição preliminar das ordens do modelo. Em ambas, observou-se um valor elevado no primeiro desfasamento, enquanto os desfasamentos seguintes apresentaram valores próximos de zero. Com base neste comportamento, foram consideradas ordens autorregressivas e de média móvel baixas, posteriormente comparadas através dos critérios AIC, BIC e do teste de Ljung–Box.

J. Engenharia de variáveis

A variável-alvo foi definida como a precipitação do dia seguinte ($t + 1$). Foram utilizados exclusivamente dados disponíveis até ao dia t, evitando informação posterior ao momento da previsão.

Foram construídos 21 preditores, incluindo o mês, um indicador da época chuvosa, a precipitação do dia actual, as defasagens

de 1, 3 e 7 dias, os acumulados de precipitação de 3, 7 e 30 dias, os valores actuais de temperatura, humidade, pressão e vento, bem como as médias móveis de 3 e 7 dias dessas variáveis.

Após a aplicação da janela de 30 dias, necessária para calcular os acumulados e as médias móveis, permaneceram 10.927 registos completos para a modelação.

4. RESULTADOS

A. Análise exploratória da precipitação

Das 10.957 observações diárias, entre 1 de Janeiro de 1995 e 30 de Dezembro de 2024, a precipitação média diária foi de 1,87 mm, com desvio padrão de 6,28 mm. A mediana foi igual a 0 mm e o terceiro quartil correspondeu a 0,8 mm, indicando uma distribuição assimétrica, com elevada concentração de valores nulos e ocorrência ocasional de eventos intensos.

Dos 10.957 dias analisados, 6.544 não registaram precipitação, correspondendo a 59,72% da série. O maior valor diário observado foi de 125,3 mm, registado em 22 de Janeiro de 2004. Este valor foi mantido por representar um evento extremo válido.

As variáveis meteorológicas utilizadas como preditoras apresentaram médias de 22,85 °C para a temperatura, 73,35% para a humidade, 1010,24 hPa para a pressão e 21,28 km/h para a velocidade máxima do vento.

Tabela 2. Estatísticas descritivas das variáveis analisadas

Variável	Média	DP	Mín.	Mediana	Máx.
Temperatura (°C)	22,85	2,91	13,00	23,00	32,10
Precipitação (mm)	1,87	6,28	0,00	0,00	125,30
Humidade (%)	73,35	8,63	25,10	74,70	93,70
Pressão (hPa)	1010,24	5,54	993,73	1009,74	1031,56
Vento máximo (km/h)	21,28	5,72	7,40	20,70	47,70

B. Distribuição mensal da precipitação

A Figura 1 evidencia uma sazonalidade marcada. Os maiores valores e a maior dispersão ocorreram sobretudo em Janeiro, Fevereiro, Março, Novembro e Dezembro. Entre Maio e Agosto observaram-se menores volumes e maior concentração de valores próximos de zero.

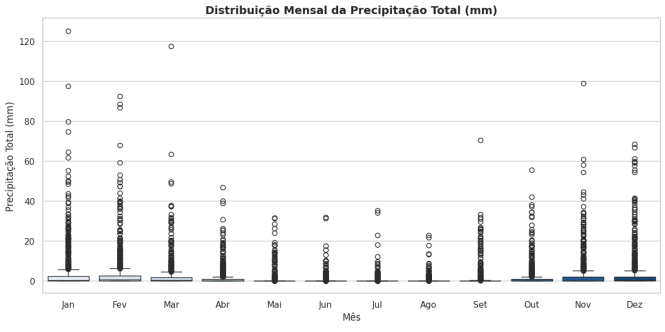


Fig. 1. Distribuição mensal da precipitação total, 1995–2024.

C. Precipitação acumulada e intensidade da chuva

A Figura 2 apresenta a precipitação total acumulada por mês e a distribuição da intensidade da chuva nos dias chuvosos. Os maiores acumulados ocorreram em Janeiro, Fevereiro e Dezembro, enquanto Junho, Julho e Agosto apresentaram os menores valores.

A distribuição da intensidade apresenta assimetria positiva. A maioria dos eventos foi de baixa intensidade, enquanto os eventos mais intensos foram menos frequentes. A escala logarítmica permite visualizar simultaneamente eventos frequentes e raros.

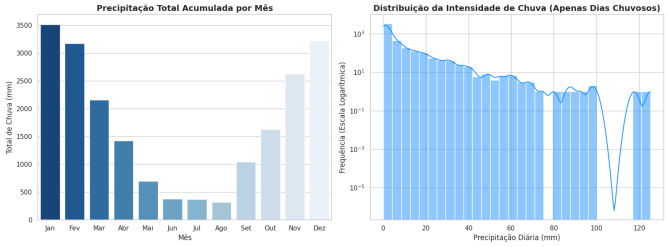


Fig. 2. Precipitação acumulada por mês e distribuição da intensidade da chuva nos dias chuvosos, 1995–2024.

D. Decomposição STL

A Figura 3 mostra uma sazonalidade anual regular e uma tendência não monotónica. A componente sazonal apresenta valores negativos na época seca e positivos na época chuvosa. Os resíduos concentram-se em torno de zero, mas incluem desvios superiores a 100 mm associados a eventos extremos.

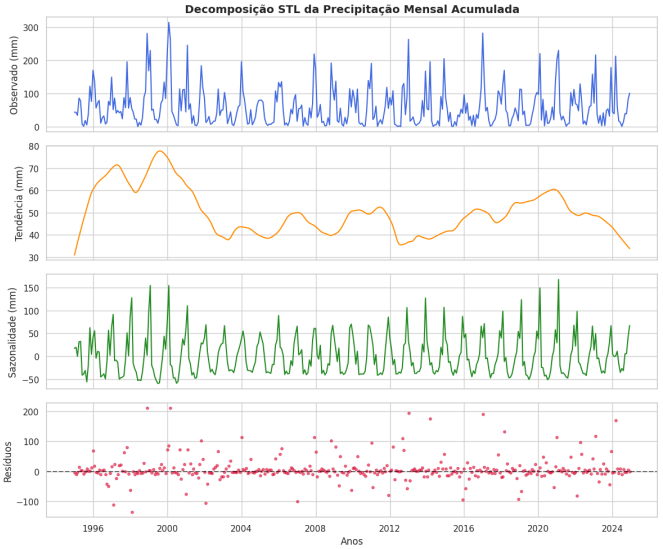


Fig. 3. Decomposição STL da precipitação mensal acumulada, 1995–2024.

E. Tendência temporal da precipitação

O teste de Mann–Kendall aplicado à série diária indicou uma tendência decrescente, com $p = 0{,}0104$ e $\tau = -0{,}0145$. O declive de Sen foi apresentado como aproximadamente zero devido ao arredondamento e à elevada frequência de dias sem chuva.

Tabela 3. Teste de Mann–Kendall e declive de Sen da precipitação diária

Variável	Tendência	p-valor	τ	Sen
Precipitação diária	Decrescente	0,0104	-0,0145	0,00000

F. Correlação entre variáveis

A Figura 4 apresenta a matriz de correlação de Pearson. A humidade média apresentou a maior correlação positiva com a precipitação ($r = 0{,}32$), seguida da velocidade máxima do vento ($r = 0{,}17$). A pressão média apresentou correlação negativa ($r = -0{,}13$), enquanto a temperatura apresentou relação linear muito fraca ($r = 0{,}05$).

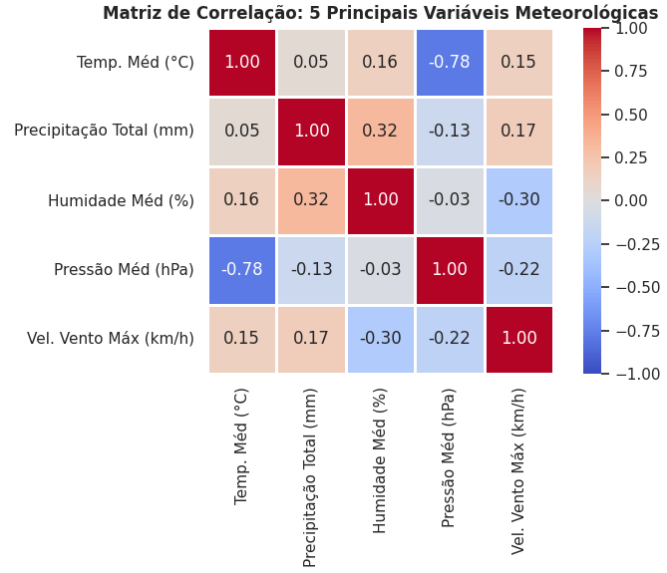


Fig. 4. Matriz de correlação de Pearson entre as variáveis meteorológicas diárias, 1995–2024.

G. Engenharia de variáveis

Foram construídos 21 preditores com informação do dia t ou de dias anteriores. Foram incluídas variáveis de calendário, defasagens e acumulados da precipitação, além dos valores actuais e das médias móveis de 3 e 7 dias das variáveis meteorológicas. Após a aplicação da janela de 30 dias, restaram 10.927 registos completos.

H. Separação temporal e controlo do vazamento de informação

Os 10.927 registos foram divididos cronologicamente, sem embaralhamento, em treino, validação e teste. O conjunto de treino teve 7.648 registos, o de validação 1.639 e o de teste 1.640. A variável-alvo correspondeu à precipitação do dia seguinte, e nenhum preditor utilizou informação posterior ao dia t.

I. Modelo SARIMAX

I.1. Teste de Dickey–Fuller aumentado

O teste ADF apresentou estatística de $-10{,}35139$ e valor de $p = 2{,}53126 \times 10^{-18}$. A série foi considerada estacionária, permitindo adoptar $d = 0$ no modelo SARIMAX.

I.2. Identificação da ordem do modelo

A ACF e a PACF apresentaram os maiores valores no primeiro desfasamento, tendo sido considerada inicialmente a ordem $(p, d, q) = (1, 0, 1)$.

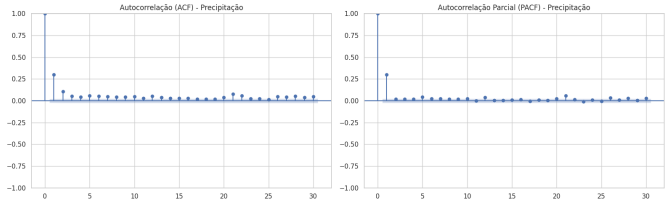


Fig. 5. Funções de autocorrelação e autocorrelação parcial da precipitação.

I.3. Representação da sazonalidade

A sazonalidade foi representada através do mês e de um indicador binário da época chuvosa. Estas variáveis foram complementadas por defasagens, acumulados e médias móveis.

J. Modelo Random Forest

J.1. Validação cruzada temporal

A validação cruzada temporal foi realizada em cinco divisões sucessivas, preservando a ordem cronológica. O Random Forest apresentou MAE médio de 2,3734 mm, RMSE médio de 5,8043 mm e R^2 médio de 0,1369.

J.2. Optimização dos hiperparâmetros

A optimização foi realizada com o método *GridSearchCV*, considerando 24 combinações e três divisões de validação. A melhor configuração utilizou 150 árvores, profundidade máxima de 8, duas observações mínimas por folha e duas observações mínimas para dividir um nó.

O MAE diminuiu de 2,3441 para 2,2967 mm, enquanto o RMSE diminuiu de 5,9191 para 5,8569 mm.

K. Classificação do risco pluviométrico

As previsões contínuas do SARIMAX(1,0,1) e do Random Forest foram convertidas em cinco categorias: sem chuva, chuva fraca, chuva moderada, chuva forte e chuva extrema.

O SARIMAX apresentou acurácia de 0,47, F1-score macro de 0,17 e Kappa de Cohen de 0,0909. O Random Forest apresentou acurácia de 0,39, F1-score macro de 0,18 e Kappa de Cohen de 0,0002.

L. Matrizes de confusão

As matrizes de confusão dos dois regressores são apresentadas na Figura 6.

M. Métricas robustas de classificação

No conjunto de teste, observaram-se 898 dias sem chuva, 657 dias de chuva fraca, 45 dias de chuva moderada, 37 dias de chuva forte e 3 dias de chuva extrema.

A *balanced accuracy* foi de 0,2226 para o SARIMAX e de 0,2433 para o Random Forest. O F1-score macro foi de 0,1717 e 0,1780, respectivamente.

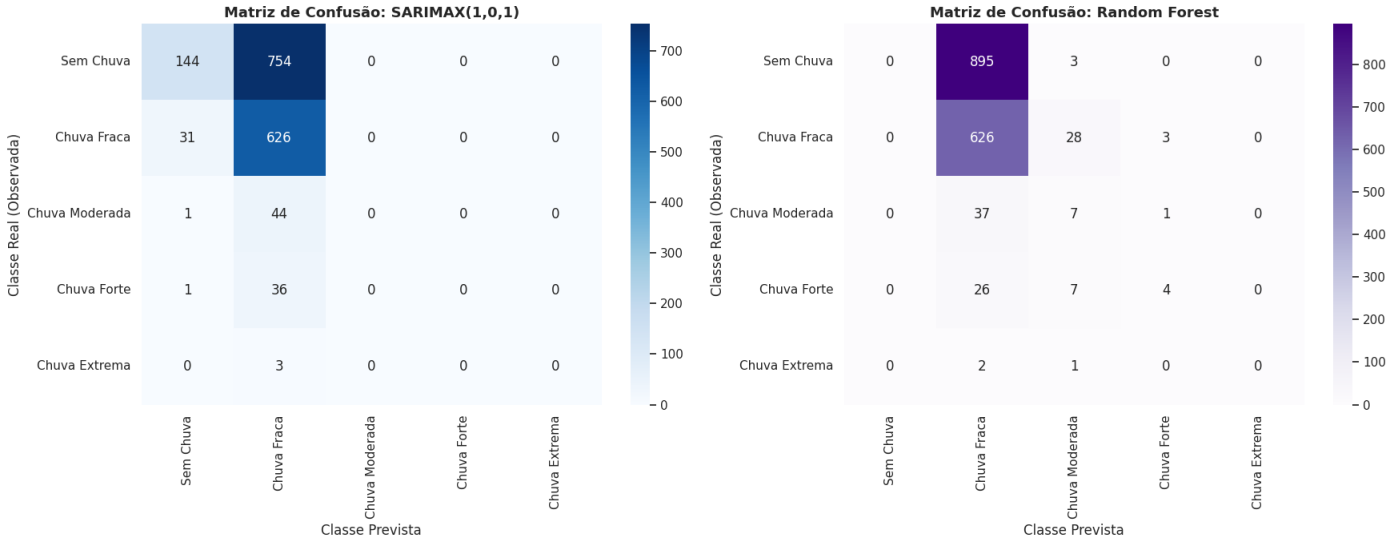


Fig. 6. Matrizes de confusão do SARIMAX(1,0,1) e do Random Forest após a conversão das previsões em categorias de risco.

Tabela 5. Avaliação final dos modelos no conjunto de teste

Modelo	MAE (mm)	RMSE (mm)	R^2	Correlação (r)
SARIMAX(1,0,1)	2,6852	5,9886	0,0683	0,2642
Random Forest (base)	2,4196	5,7549	0,1396	0,3959
Random Forest (optimizado)	2,3569	5,6975	0,1567	0,4040

N. Importância das variáveis

Tabela 4. Dez variáveis mais importantes no modelo Random Forest

Variável	MDI	Permutação	Desvio padrão
Precipitação no dia actual	0,193447	0,453979	0,041815
Pressão média	0,120732	0,160370	0,025765
Precipitação acumulada em 7 dias	0,049400	0,104985	0,022341
Pressão média – média móvel de 3 dias	0,041079	0,081830	0,012803
Humidade média	0,090522	0,073981	0,005661
Temperatura média	0,054802	0,027177	0,010799
Velocidade máxima do vento	0,038752	0,025180	0,011358
Temperatura média – média móvel de 7 dias	0,031191	0,016407	0,002924
Precipitação acumulada em 3 dias	0,026184	0,014178	0,004796
Velocidade máxima do vento – média móvel de 7 dias	0,051919	0,012749	0,006501

A importância das variáveis foi avaliada através da importância MDI, calculada no treino, e da importância por permutação, calculada no teste. A precipitação do dia actual apresentou o maior valor nas duas medidas, seguida da pressão média e da precipitação acumulada em sete dias.

N.1. Avaliação final no conjunto de teste

A avaliação final foi realizada no conjunto de teste, constituído por 1.640 observações que não participaram no treino nem na selecção dos modelos. Os resultados são apresentados na Tabela 5.

O Random Forest optimizado apresentou MAE de 2,3569 mm, RMSE de 5,6975 mm, R^2 de 0,1567 e correlação de 0,4040. O SARIMAX(1,0,1) apresentou MAE de 2,6852 mm, RMSE de 5,9886 mm, R^2 de 0,0683 e correlação de 0,2642. O Random Forest base apresentou MAE de 2,4196 mm, RMSE de 5,7549 mm, R^2 de 0,1396 e correlação de 0,3959.

N.2. Matrizes de confusão dos classificadores dedicados

As matrizes de confusão dos classificadores Random Forest e XGBoost são apresentadas na Figura 7. As linhas representam as categorias observadas e as colunas correspondem às categorias previstas.

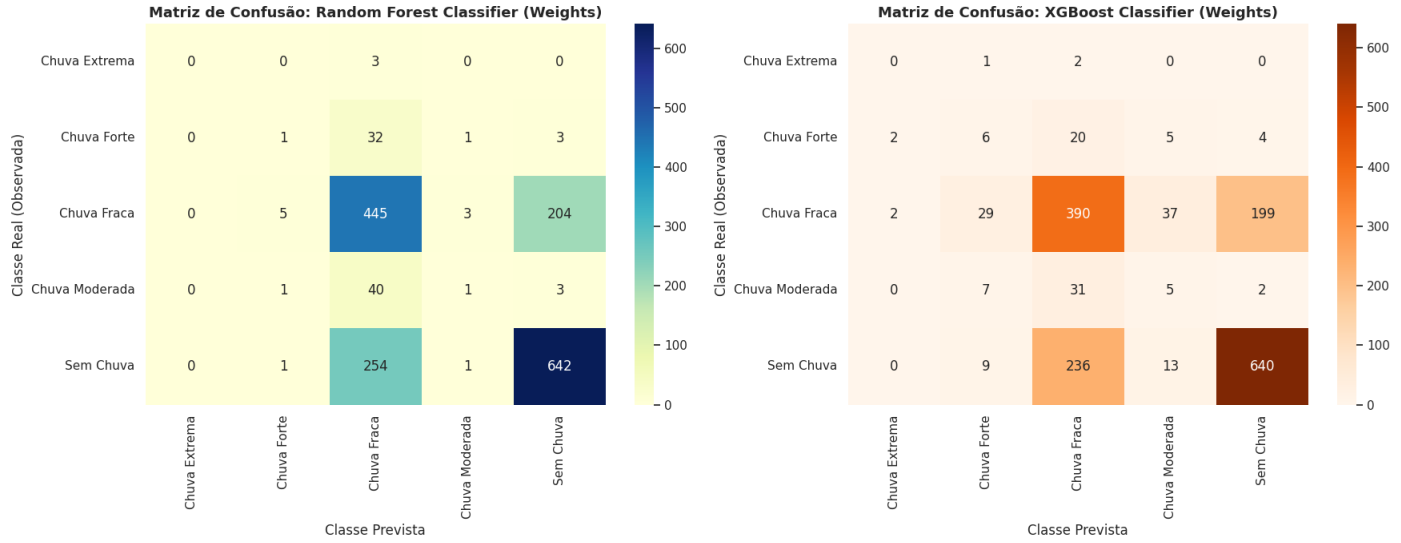


Fig. 7. Matrizes de confusão dos classificadores Random Forest e XGBoost para as categorias de risco pluviométrico.

5. DISCUSSÃO

A. Sazonalidade e variabilidade da precipitação

Os resultados mostram que a precipitação em Maputo apresenta uma sazonalidade marcada. Os maiores acumulados ocorreram principalmente entre Novembro e Março, enquanto os menores valores foram observados entre Maio e Agosto. Este padrão também foi evidenciado pela decomposição STL, cuja componente sazonal apresentou um ciclo anual regular.

A precipitação diária apresentou elevada variabilidade, com 59,72% dos dias sem chuva e poucos eventos de intensidade elevada. O máximo diário de 125,3 mm, registado em 22 de Janeiro de 2004, demonstra a ocorrência de eventos extremos dentro da série. Esta distribuição, caracterizada por muitos valores nulos e uma cauda direita acentuada, constitui um desafio para a previsão diária e para a classificação das categorias de risco.

B. Tendência temporal da precipitação

O teste de Mann–Kendall aplicado à série diária indicou uma tendência decrescente estatisticamente significativa, com $p = 0{,}0104$ e $\tau = -0{,}0145$. Contudo, o baixo valor absoluto de τ indica uma tendência monotónica muito fraca. Além disso, o declive de Sen foi aproximadamente nulo.

As séries agregadas anuais e sazonais não apresentaram tendências estatisticamente significativas. Assim, os resultados não permitem afirmar que tenha ocorrido uma redução consistente da precipitação em todo o período de 1995 a 2024. A significância observada na série diária deve ser interpretada com cautela, considerando a elevada frequência de dias secos, a sazonalidade e a variabilidade da precipitação.

C. Comparação dos modelos de previsão

Na previsão do volume de precipitação do dia seguinte, o Random Forest optimizado apresentou o melhor desempenho no conjunto de teste. O modelo obteve MAE de 2,3569 mm, RMSE de 5,6975 mm, R^2 de 0,1567 e correlação de 0,4040. O Random Forest base apresentou MAE de 2,4196 mm, RMSE de 5,7549 mm, R^2 de 0,1396 e correlação de 0,3959. Por sua vez, o SARIMAX(1,0,1) apresentou MAE de 2,6852 mm, RMSE de 5,9886 mm, R^2 de 0,0683 e correlação de 0,2642.

A superioridade do Random Forest sugere que as relações entre a precipitação e os preditores utilizados não são inteiramente lineares. O modelo também pode explorar interacções entre as variáveis meteorológicas, as defasagens e os acumulados recentes da precipitação. A optimização dos hiperparâmetros produziu uma melhoria relativamente pequena, com redução de 2,02% no MAE e de 1,05% no RMSE, indicando que a configuração inicial já apresentava desempenho razoável.

Apesar da superioridade do Random Forest, o valor de R^2 obtido no teste foi moderado. Este resultado indica que uma parte considerável da variabilidade diária da precipitação não foi explicada pelos preditores utilizados. A capacidade preditiva deve, portanto, ser considerada útil para apoio à decisão, mas insuficiente para representar isoladamente um sistema operacional de previsão de eventos extremos.

D. Classificação do risco pluviométrico

A conversão das previsões contínuas dos regressores em categorias de risco apresentou desempenho limitado. O SARIMAX obteve acurácia de 0,47, *balanced accuracy* de 0,2226 e F1-score macro de 0,1717. O Random Forest Regressor obteve acurácia de 0,39, *balanced accuracy* de 0,2433 e F1-score macro de 0,1780.

Os classificadores dedicados apresentaram resultados superiores aos obtidos pela conversão das previsões dos regressores. O Random Forest Classifier obteve *balanced accuracy* de 0,2883 e F1-score macro de 0,2879, enquanto o XGBoost Classifier apresentou *balanced accuracy* de 0,3159 e F1-score macro de 0,3097.

Apesar desse desempenho, nenhum dos classificadores identificou correctamente os três eventos da categoria "Chuva Extrema". A reduzida frequência das classes de chuva forte e extrema também se reflectiu nos baixos valores de *recall* e F1-score. Assim, os resultados indicam que a classificação das categorias menos frequentes continua a ser uma limitação importante.

E. Importância das variáveis

A precipitação do dia actual foi a variável mais importante na previsão da precipitação do dia seguinte, tanto pela importância MDI como pela importância por permutação. A pressão média apresentou a segunda maior importância por permutação, seguida da precipitação acumulada em sete dias e da pressão

média calculada para três dias.

A importância das defasagens e dos acumulados confirma a relevância da memória recente da precipitação. As variáveis meteorológicas também contribuíram para a previsão, embora com valores inferiores aos das variáveis directamente relacionadas com a precipitação. Estes resultados devem ser interpretados como contribuição preditiva dentro do Random Forest, não como evidência de relações causais.

F. Implicações para a tomada de decisão

Os resultados podem apoiar decisões relacionadas com o planeamento agrícola, a gestão da drenagem urbana, a organização de actividades de campo e a preparação de operações afectadas pela ocorrência de chuva. A previsão do volume pode contribuir para antecipar dias com maior probabilidade de precipitação, enquanto a classificação pode auxiliar na organização de diferentes níveis de resposta.

Contudo, devido à limitada identificação dos eventos extremos, os modelos não devem ser utilizados de forma autónoma para emitir alertas críticos. A sua aplicação deve ser combinada com observações locais, previsões meteorológicas oficiais e informação complementar sobre ciclones, humidade do solo, circulação atmosférica e condições de drenagem.

G. Limitações do estudo

Este estudo apresenta algumas limitações. Primeiro, a análise baseou-se em dados de reanálise ERA5, que podem não representar totalmente a variabilidade local da precipitação na Província de Maputo. Segundo, a distribuição das categorias de risco foi desequilibrada, com apenas três eventos extremos no conjunto de teste. Terceiro, os regressores foram convertidos posteriormente em categorias, não tendo sido treinados originalmente para a classificação do risco.

Além disso, o desempenho preditivo pode ser melhorado com a inclusão de variáveis adicionais, como índices de circulação atmosférica, ocorrência de ciclones, humidade do solo, temperatura da superfície do mar e informação topográfica. A validação com dados observacionais locais também poderá melhorar a avaliação da utilidade operacional dos modelos.

6. CONCLUSÃO

Este estudo comparou o desempenho dos modelos SARIMAX e Random Forest na previsão da precipitação do dia seguinte e na classificação do risco pluviométrico na Província de Maputo, utilizando dados de reanálise ERA5 referentes ao período de 1995 a 2024.

A análise exploratória mostrou que a precipitação apresenta forte sazonalidade, com maiores acumulados entre Novembro e Março e menores valores entre Maio e Agosto. A série também apresentou elevada variabilidade, com 59,72% dos dias sem chuva e ocorrência ocasional de eventos intensos. O teste de Mann–Kendall indicou uma tendência decrescente na série diária, mas a magnitude do efeito foi muito reduzida e as séries agregadas anuais e sazonais não apresentaram tendências estatisticamente significativas.

Na previsão do volume de precipitação, o Random Forest optimizado apresentou o melhor desempenho no conjunto de teste, com MAE de 2,3569 mm, RMSE de 5,6975 mm, R^2 de 0,1567 e correlação de 0,4040. O modelo superou o SARIMAX(1,0,1), que apresentou MAE de 2,6852 mm, RMSE de 5,9886 mm, R^2 de 0,0683 e correlação de 0,2642. Assim, para a previsão quantitativa da precipitação do dia seguinte, o Random Forest apresentou maior desempenho preditivo.

A precipitação do dia actual foi a variável mais importante para o Random Forest, seguida da pressão média, da precipitação acumulada em sete dias e da pressão média calculada para três dias. Estes resultados mostram a relevância da precipitação recente e das condições atmosféricas na previsão do dia seguinte.

Na classificação do risco pluviométrico, os classificadores dedicados apresentaram melhor desempenho do que a conversão posterior das previsões dos regressores em categorias. O XGBoost apresentou os melhores resultados, com *balanced accuracy* de 0,3159 e F1-score macro de 0,3097, seguido do Random Forest Classifier, com valores de 0,2883 e 0,2879, respectivamente. Contudo, nenhum modelo identificou correctamente os eventos de chuva extrema.

Conclui-se que o Random Forest optimizado é o modelo mais adequado entre os modelos avaliados para prever o volume diário de precipitação em Maputo, enquanto o XGBoost apresentou o melhor desempenho na classificação das categorias de risco. Apesar disso, os modelos devem ser utilizados como ferramentas de apoio à tomada de decisão e não como sistemas autónomos de alerta, sobretudo para eventos extremos.

A utilização operacional destes resultados requer validação com observações pluviométricas locais e a inclusão de variáveis adicionais, como ciclones, circulação atmosférica, humidade do solo, temperatura da superfície do mar e informação topográfica. Estudos futuros poderão também testar métodos específicos para dados desequilibrados e modelos desenvolvidos directamente para a classificação de eventos extremos.

REFERÊNCIAS

1. World Meteorological Organization, “Mozambique takes strides towards early warnings for all,” (2024).
2. H. Hersbach *et al.*, “The era5 global reanalysis,” Q. J. Royal Meteorol. Soc. **146**, 1999–2049 (2020).
3. C. Funk *et al.*, “The climate hazards infrared precipitation with stations: A new environmental record for monitoring extremes,” Sci. Data **2**, 150066 (2015).
4. R. Muleia *et al.*, “Assessing the vulnerability and adaptation needs of mozambique to climate change,” Int. J. Environ. Res. Public Health **21**, 532 (2024).
5. J. P. Matos *et al.*, “Evaluating compound flooding risks in coastal cities under climate change: The maputo case study, in mozambique,” Sustainability **15**, 14497 (2023).
6. World Bank, “Mozambique: Climate change knowledge portal,” (2025).
7. A. J. Manhique, C. J. C. Reason, and R. Barimalala, “Rainfall onset and cessation over mozambique and relationship with sea surface temperature and atmospheric patterns,” Int. J. Climatol. (2023).
8. R. Barimalala, R. C. Blamey, F. Desbiolles, and C. J. C. Reason, “Variability in the mozambique channel trough and impacts on southeast african rainfall,” J. Clim. **33**, 749–766 (2020).
9. M. F. Horan, F. Kucharski, and M. Ashfaq, “Seasonal variability and predictability of monsoon precipitation in southern africa,” Environ. Res. Lett. **19**, 034010 (2024).
10. D. A. Lavers, A. Simmons, F. Vamborg, and M. J. Rodwell, “An evaluation of era5 precipitation for climate monitoring,” Q. J. Royal Meteorol. Soc. **148**, 3152–3165 (2022).
11. D. Terblanche, A. Lynch, Z. Chen, and S. Sinclair, “Era5-derived precipitation: Insights from historical rainfall networks in southern africa,” J. Appl. Meteorol. Climatol. **61**, 1473–1484 (2022).
12. Y. Lai and D. A. Dzombak, “Use of the autoregressive integrated moving average model to forecast near-term regional temperature and precipitation,” Weather. Forecast. **35**, 959–976 (2020).
13. S. Mulla, C. B. Pande, and S. K. Singh, “Time series forecasting of

monthly rainfall using sarimax model," Water Resour. Manag. **38**, 1825–1846 (2024).
14. P. Unnikrishnan and V. Jothiprakash, "Hybrid ssa-arima-ann model for forecasting daily rainfall," Water Resour. Manag. **34**, 3609–3623 (2020).
15. L. Breiman, "Random forests," Mach. Learn. **45**, 5–32 (2001).
16. J. Wang, R. K. W. Wong, M. Jun *et al.*, "Statistical and machine learning methods applied to the prediction of different tropical rainfall types," Environ. Res. Commun. **3**, 111001 (2021).
17. F. Grazzini *et al.*, "Improving forecasts of precipitation extremes over northern and central italy using machine learning," Q. J. Royal Meteorol. Soc. **150**, 3167–3181 (2024).
18. N. Tihi and S. Popov, "A comparison of arima and random forest time series models for urban drought prediction," in *Proceedings of the International Scientific Conference – Sinteza 2024*, (2024), pp. 51–56.
19. M. U. S. Khan *et al.*, "Comparative analysis of different rainfall prediction models: A case study of aligarh city, india," Results Eng. **23**, 102093 (2024).
20. B. Casati *et al.*, "Forecast verification: Current status and future directions," Meteorol. Appl. **15**, 3–18 (2008).
21. F. Bouttier and H. Marchal, "Probabilistic short-range forecasts of high-precipitation events: Optimal decision thresholds and predictability limits," Nat. Hazards Earth Syst. Sci. **24**, 2793–2816 (2024).
22. H. B. Mann, "Nonparametric tests against trend," Econometrica **13**, 245–259 (1945).
23. M. G. Kendall, *Rank Correlation Methods* (Griffin, 1975), 4th ed.
24. P. K. Sen, "Estimates of the regression coefficient based on kendall's tau," J. Am. Stat. Assoc. **63**, 1379–1389 (1968).
25. R. B. Cleveland, W. S. Cleveland, J. E. McRae, and I. Terpenning, "Stl: A seasonal-trend decomposition procedure based on loess," J. Off. Stat. **6**, 3–73 (1990).
26. D. A. Dickey and W. A. Fuller, "Distribution of the estimators for autoregressive time series with a unit root," J. Am. Stat. Assoc. **74**, 427–431 (1979).